




기계학습 (Machine learning)

AI 신약학과

신현길

 + Machine Learning = 

Data

 + Artificial Intellifence = 

Data

 + Generative AI = 

Data

 + Agentic AI = 


Data

혼돈의 데이터 정리

- 교수가 뭐 하라는데, 뭐 하라는 건지 모르겠음.
- 목적이 불분명
 - A, B, C를 하세요. (왜 하는지 설명이 부족)
 - 낯선 형태의 데이터를 다루는 데서 오는 혼돈
 - 효율적 학습을 위해 낯선 환경에 적응하는 시간도 필요
- 원래 현업에서 데이터를 정리하는 방식
 - 데이터를 생산한 사람과 상당 기간 논의
(수개월~)



이 수업 시간에 진행하는 기계학습 모델




데이터에서 모델 개발에
필요한 컬럼

입력

출력

SMILES	Endpoint	Response	Response_Unit
[H]OCCO lp:1:2,4:2,Sg:n:1,2,3::ht	Positive reaction	0	%
[Na+].[Na+].[Na+].[Na+].OO.OO.OO.[O-]C([O-])=O.[O-]C([O-])=O	Positive reaction	3.8	%
[Na+].[Na+].[O-]C([O-])=O	Positive reaction	0	%
[Na+].[Na+].OC(=O)CN(CCN(CC(O)=O)CC([O-])=O)CC([O-])=O	Positive reaction	0	%
[Na+].[O-][B](=O)=O	Positive reaction	3.9	%
[Na+].CCCCCCCCCCCCOS([O-])(=O)=O	Positive reaction	83.1	%

어떤 데이터를 피해야 하는가?



A diagram illustrating a process where data is processed using machine learning to produce a negative result. On the left, a database icon (cylinder) with a poop emoji inside is labeled "Data". This is followed by a plus sign, the text "Machine Learning", an equals sign, and a larger poop emoji.

$$\text{Data} + \text{Machine Learning} = \text{Poop}$$

- 동일한 물질인데 실험값이 다르게 기재되어 있는 경우
 - 동일한 물질: chemical name, CASRN, DTXSID, smiles
- 서로 다른 조건에서 실험이 진행된 경우
 - Human, rabbit / Chemical, mixture

Clean data

- 데이터 분석을 하는 이유
 - 데이터는 늘 부족하다
 - 데이터가 많아 보여도 정리하면 많이 제거됨 (데이터 내 동일 물질이 여러 번 기재되어 있음)
- 데이터를 살펴보는 목적
 - 조건이 다르지만 함께 사용할 수 있는 데이터 탐색
 - 데이터 퀄리티에 대한 약간의 타협을 통해 추가 데이터 확보 (어디까지 양보를 할 수 있을까?)

[Draize Skin Irritation/Corrosion Test ▲](#)

This test assesses skin irritation or corrosion caused by a single application of test substance to the skin of an experimental animal ([Test Guideline 404, OECD 2015](#)). Assessments are conducted up to 14 days after test substance application.

Data sources:

- [ICCVAM evaluation \(2001\)](#) of in vitro methods (EpiDerm, EPISKIN, and rat skin transcutaneous electrical resistance assay).
- Submissions to [EPA](#) of six-pack acute toxicity studies for pesticide registration.
 - Include data on formulations and active ingredients.
 - Curated to obtain [CASRNs](#), improve consistency of units, and assign EPA and [GHS](#) toxicity categories as needed based on defined criteria.
- Data compiled for an analysis of variability in the rabbit skin irritation assay, as described in [Rooney et al. 2021](#).

Endpoints:

- EPA and GHS skin irritation hazard classifications.
 - [EPA](#) ▲
 - [GHS](#) ▲

[Four-hour Human Patch Test ▲](#)

Data were collected from four-hour human patch tests (4h HPT).

Data sources:

- Scores from the [4h HPT](#) from Table 1 of [Basketter et al. 2012](#).

Endpoints:

- Positive reaction (percent): percentage of tested individuals with a positive reaction to test substance.
- Qualitative classification: the reported qualitative degree of skin irritation, based on the EU classification system.
 - Corrosive: response observed is significantly stronger and faster than response to 20% sodium dodecyl sulfate.
 - Irritant: response observed is significantly greater than or similar to response observed with 20% sodium dodecyl sulfate.
 - Not classified: response observed is substantially and statistically significantly lower than response observed with 20% sodium dodecyl sulfate.


모델 활용 측면에서 가치 있는 데이터?

- AI신약에서 기계학습 모델을 개발하는 목적
 - 사람에게 안전한 물질을 찾아내는 것
 - 사람에게 시험하기 전 동물 시험을 통해 인체유해성 확인
 - 동물 시험 전 세포 실험을 통해 후보물질 도출
- 사람 > 동물 > 세포
- 데이터 양이 많다 = 생산하기 쉽다 (세포 > 동물 > 사람)
 - 데이터 생산이 쉽다 = 데이터 생산 비용이 저렴하다


데이터는 얼마나 필요할까?

- 데이터는 많을수록 좋다? (**양질**의 데이터가 많을수록 좋다)
 - 양질의 데이터는 메타데이터가 꼼꼼하게 기록되어 있음 (데이터가 생산된 조건이 정확하게 기재되어 있어 신뢰할 수 있음)
- 기준은 없지만...
 - 최소 30개라고 교육하는 곳이 있긴 합니다만...
 - 20개로 예측 모델을 개발한 사례도 있음 (나노 물질, 물질 합성 비용이 너무 높아서 다수의 실험이 어려운 경우. 미미한 실험 조건 차이가 실험 결과에 지대한 영향을 미치는 경우.)
 - 회귀 모델인 경우 실험값 분포를 확인할 것 (정규분포모양, bell shape)
 - 분류 모델인 경우 라벨 균형을 확인할 것 (True/False 비율이 1:1과 유사)

어떤 데이터를 피해야 하는지 언제 알게 될까?



- 모델 개발 경험이 없다면, 모델 개발 전 데이터 퀄리티 판단 불가. (데이터 수집한 사람도 모름...)
 - 어마어마한 데이터가 있다고 협력 연구를 제안했는데...
 - 이미 프로젝트는 수개월간 진행했는데, 초기화...
- 일반적으로 모델 개발 후, 성능 개선이 되지 않으면 그때부터 고민하기 시작. (validation 시점에 파악)



Pandas를 사용해야 하는 이유

- 프로젝트 기간 동안 데이터 선별 과정을 여러 차례 반복하게 됨
 - 데이터를 추가로 모으거나, 데이터 선택 조건이 바뀔 때마다 엑셀에서 필터링(chemical, human, positive reaction, ...) 반복???
 - Pandas로 데이터 정리 과정을 자동화 해 놓는 것이 장기적으로 효율적
- 데이터 분석 편의성 (친해지려면 시간이 조금 필요하지만...)
 - 컬럼에 있는 데이터 개수 파악 (value_count)
 - 데이터 분포 시각화 (matplotlib)

$\wedge$

pandas.DataFrame.to_xml

```
read_excel()
```

Supports an option to read a single sheet or a list of sheets.

Pandas에서 excel 파일 읽는 방법에 대한 설명

The file can be read using the file name as string or an open file object:

```
>>> pd.read_excel("tmp.xlsx", index_col=0)
      Name  Value
0  string1      1
1  string2      2
2  #Comment      3
```

스크롤을 내려보면 사용 사례 소개

```
>>> pd.read_excel(open("tmp.xlsx", "rb"), sheet_name="Sheet3")
      Unnamed: 0      Name  Value
0              0  string1      1
1              1  string2      2
2              2  #Comment      3
```

Index and header can be specified via the *index_col* and *header* arguments

```
>>> pd.read_excel("tmp.xlsx", index_col=None, header=None)
      0      1      2
0  NaN      Name  Value
1  0.0  string1      1
2  1.0  string2      2
3  2.0  #Comment      3
```

Column types are inferred but can be explicitly specified

```
>>> pd.read_excel(
...     "tmp.xlsx", index_col=0, dtype={"Name": str, "Value": float}
... )
      Name  Value
0  string1  1.0
1  string2  2.0
2  #Comment  3.0
```

True, False, and NA values, and thousands separators have defaults, but can be explicitly specified, too. Supply the values you would like as strings or lists of strings!

📶

Untitled notebook

출처

☐

+ 소스 추가

🔍

웹에서 새 소스를 검색하세요

🌐 웹 ▾

🔍 Fast Research ▾

→

📄

저장된 소스가 여기에 표시됩니다

위의 소스 추가를 클릭하여 PDF, 웹사이트, 텍스트, 동영상 또는 오디오 파일을 추가하세요. 또는 Google Drive에서 파일을 직접 가져올 수 있습니다.

채팅

⌵ ⋮

×

사용자의 문서를 활용해 AI 오디오 및 동영상 오버뷰 만들기

🔍

웹에서 새 소스를 검색하세요

🌐 웹 ▾

🔍 Fast Research ▾

→

또는 파일 드롭

PDF, 이미지, 문서, 오디오 등

📁 파일 업로드

🌐 📺 웹사이트

📁 Drive

📄 복사된 텍스트

시작하려면 출처를 업로드하세요.

소스 0개 →

스튜디오

☐

🎧 AI 오디오 오버뷰

📄 슬라이드 자료

📺 동영상 개요

🧠 마인드맵

📄 보고서

📄 플래시카드

📄 퀴즈

📊 인포그래픽

📊 데이터 표

✎

스튜디오 출력이 여기에 저장됩니다

소스를 추가한 후 클릭하여 AI 오디오 오버뷰, 학습 가이드, 마인드맵 등을 추가해 보세요.

📄 메모 추가

NotebookLM이 부정확한 정보를 표시할 수 있으므로 대답을 다시 한번 확인하세요.



출처



+ 소스 추가

출처 추가

🔍 웹에서 새 소스를 검색하세요



웹



Fast Research



모든 소스 선택



pandas.read_excel — pandas 3.0.1 documenta...



채팅



지금 주피터 노트북에서 엑셀 파일을 읽어오려고 하는데,
웹페이지에 소개된 예시 코드를 바탕으로 간략한 코드 작성해줘. (나 pandas 처음 써봄)

Pandas를 처음 사용하시는군요! 주피터 노트북에서 엑셀 파일을 읽어오는 가장 기본적이고 간략한 코드를 안내해 드립니다. 소스 문헌의 내용을 바탕으로 작성했습니다 1 2 .

1. 기본 코드 (가장 쉬운 방법)

먼저 pandas 라이브러리를 불러온 뒤, `read_excel` 함수를 사용해 파일을 읽습니다.

```
import pandas as pd
```

```
# 엑셀 파일 읽기 (파일명이 'data.xlsx'인 경우)  
# 파일이 주피터 노트북 파일(.ipynb)과 같은 폴더에 있어야 합니다.  
df = pd.read_excel('data.xlsx')
```

```
# 읽어온 데이터의 앞부분 5행 확인하기  
df.head()
```

2. 주요 옵션 설명 (필요에 따라 추가하세요)

문헌에 따르면 상황에 따라 다음과 같은 옵션을 추가하여 더 정확하게 데이터를 불러올 수 있습니다.

- **특정 시트 읽기 (sheet_name):** 기본적으로 첫 번째 시트를 읽어옵니다 3 . 다른 시트를 읽고 싶다면 시트 이름이나 번호(0부터 시작)를 지정하세요.
 - `df = pd.read_excel('data.xlsx', sheet_name='Sheet2')` 3
- **제목 줄 지정 (header):** 데이터의 제목(컬럼명)이 첫 줄(0번 행)이 아닌 경우 행 번호를 지정합니다 4 . 만약 제목 줄이 없다면 `None`으로 설정하세요.
 - `df = pd.read_excel('data.xlsx', header=0)` 4
- **인덱스 컬럼 설정 (index_col):** 특정 열을 행의 이름(인덱스)으로 사용하고 싶을 때 사용합니다 4 .
 - `df = pd.read_excel('data.xlsx', index_col=0)` 2

입력을 시작하세요...

소스 1개



스튜디오



AI 오디오 오버뷰



슬라이드 자료



동영상 개요



마인드맵



보고서



플래시카드



퀴즈



인포그래픽



데이터 표



스튜디오 출력이 여기에 저장됩니다

소스를 추가한 후 클릭하여 AI 오디오 오버뷰, 학습 가이드, 마인드맵 등을 추가해 보세요.


📝 메모 추가

Jupyter notebook

1. Excel 파일 열기 (Data_invivo 탭 데이터 읽기)
2. 오류 메시지 읽는 방법 & 라이브러리 설치 방법
3. Pandas에서 엑셀 필터와 같은 기능 사용하는 법 (subset)
4. Pandas value_count 사용 (컬럼에 있는 값들 개수 확인)
5. Endpoint에서 positive_reaction 선택 후 histogram 시각화

생성AI로 인한 교육 성취도 격차


Student Programming Achievements: Before vs. After GenAI



*Antigravity를 이용한 visualization

뇌가 기억을 만드는 방식

- 흑역사는 오래도록 기억에 남는다
 - 실수/실패한 기억은 오래 지속. 수업시간에 실수와 실패를 많이 할 수록 사회에 나가서 실수하고 실패할 가능성은 낮아짐.
 - 자기 검열의 함정. (이거 나만 모르는거 아닐까? 다른 사람들은 다 이해한 것 같은데..)
- 실습실 컴퓨터가 고장나도 상관없으니 크게 고민하지 말고 이것저것 시도 해볼 것
 - 어차피 컴퓨터는 소모품. 수명은 5년 정도
 - 아마존의 의사결정 방식: One-way door vs two-way door



수업에 대한 피드백을 자주 해야 하는 이유

- 피드백을 짧은 간격으로 주지 않으면, 소통이 점점 어려워짐.
 - 작은 문제가 생겼을 때부터 지속적으로 자주 소통해야 문제가 커지지 않습니다.
- 수업을 듣는 사람한테는 보이지만, 수업을 진행하고 있는 사람은 잘 인지하지 못하는 오류들이 있음.
 - 수업하면서 생기는 압박감 중에 하나는... 침묵이 장시간 지속되는 것. 그래서 머리 속에 다음 할 말을 생각하느라, 학생들에게는 훨씬 보이는 오류도 저에게는 잘 안임. 그래서 도움 필요. (틀린 거 보고 그냥 넘어가지 말고....)
- 프로그래밍 관련해서 기초적인 내용이 너무 당연해서 설명을 잊어버리는 경우 발생. (그래서 생성AI 활용이 필수!)
 - 한달 전 아침 식사 메뉴 기억 안나는 거랑 비슷... (이미 루틴이 되었기 때문)
- 실무에서 경험하면서 체득한 것들은 비슷한 상황이 재현되면 그때서야 생각남.
 - 오류메세지나 문제가 생기면 그때 해결법이 생각남..
- 수업 결과물은 개인이 학기 말에 1회 제출하는 보고서입니다.
 - 초반에 조금 뒤쳐져도 괜찮습니다. 주변 학생들과 저에게 자주 도움 요청하시면서 수업 따라가면 보고서 제출에는 문제가 없는 수준으로 성장할 겁니다.

생성 AI 활용 관련

- 과거에는 학습에 오랜 시간이 소요됐지만, 지금은 생성 AI를 활용하면 학습 효율을 크게 올릴 수 있습니다.
 - 챗GPT로 공부한 고등학생이 openAI에 입사한 사례가 있어요.
- 뭘 해야 될지 잘 모르겠으면, AI와 적극적으로 대화하시면서 생각을 정리해보세요.
 - 혼자서 고민하는 것보다 누구랑 이야기 하는게 낫습니다.
- 프롬프트에 항상 포함되어야 하는 정보
 - **개인의 프로그래밍 수준.** 프로그래밍 실력에 따라 AI 답변의 유용성이 결정됨.
 - 내 **코드**와 **에러** 메시지 (에러가 발생한 상황을 전달해야 올바른 해결책을 얻을 수 있음)
 - AI와 대화를 반복할 수록 코드가 길어지는 경향이 있음. 항상 **간결하게 작성**할 것을 요청해야 함.